Raport z analizy danych Rejestru Produktów Leczniczych

Analiza zmiennych, selekcja cech i przygotowanie danych do modelowania

Autor: Julia Walencik

Indeks: 415331

Kierunek: Inżynieria i Analiza Danych

1. Zapoznanie się z biblioteką seaborn.

Seaborn to rozbudowana biblioteka oparta na matplotlib odpowiadająca za wizualizację danych. Umożliwia ona w prosty sposób tworzenie czytelnych i informacyjnych wykresów różnego typu. Za pomocą metod biblioteki można wybrać rodzaj wykresu oraz ustawiać jego właściwości, takie jak: paleta kolorów, nazwa i zakresy osi, a także wartość parametru „hue".

2. Zapoznanie się ze stroną https://dane.gov.pl/.

Strona https://dane.gov.pl/ gromadzi i udostępnia dane publiczne z administracji rządowych, samorządowych i innych organizacji publicznych w Polsce. Możliwość używania tych danych zależy od rodzaju licencji konkretnego zbioru. Większość można pobierać i korzystać do dowolnych celów, podczas gdy inne mogą być używane pod warunkiem uznania autorstwa i braku nałożenia ograniczeń, które zabroniłyby używania utworów utworzonych na podstawie zbioru danych, lub obowiązek udostępnienia tegoż utworu na tej samej licencji. Zbiory zawierające dane osobowe lub objęte innymi ograniczeniami nie są dostępne bez zezwolenia.

Dane są udostępnianie w formacie CSV, XLSX, JSON, GEOJON, PDF, XML, DOC, DOCX, GEOTIFF, HTML, JPG oraz różnych rodzajach API. Niektóre instytucje udostępniają API dostosowane pod ich typ danych. Np. Główny Urząd Statystyczny udostępnia API DBW (Dziedzinowe Bazy Wiedzy), a Ministerstwo Finansów – Trezor API.

Storna ma również Walidator API, który umożliwia sprawdzenie jakości API ze standardami. Po podaniu adresu URL prowadzącego do definicji API przeprowadzany jest test, którego wyniki zostaną wyświetlone w formie raportu. Istnieje też możliwość pobrania go w formie PDF.

3. Wybranie zestawu danych dostępnych na stronie.

Wybrany zestaw danych to Rejestr Produktów Leczniczych. Dostępne pod adresem: https://dane.gov.pl/pl/dataset/397,rejestr-produktow-leczniczych.

4. Wykonanie pierwszych etapów pipeline'u ML.

4.1. Pobranie danych i zapoznanie się z opisem.

Opis: „Rejestr Produktów Leczniczych zawiera informacje o wszystkich produktach leczniczych przeznaczonych dla ludzi oraz weterynaryjnych dopuszczonych do obrotu na terytorium Rzeczypospolitej Polskiej."

```
.. code:: ipython3

    import numpy as np
    import pandas as pd

    data =
pd.read_csv('Rejestr_Produktow_Leczniczych_calosciowy_stan_na_dzien_
20250425.csv', sep=";")

    data.shape

.. parsed-literal::

    (22305, 33)
```

Zestaw danych zawiera 22305 wiersze i 33 kolumny.

4.2. Zastosowanie danych

Dane mogą być wykorzystane w uczeniu maszynowym do tworzenia modeli klasyfikujące leki na podstawie ich składu, postaci czy innych czynników. Tego typu zdanie stanowi przykład uczenia nadzorowanego, w którym model na podstawie już oznaczanego zbioru danych, przypisuje odpowiednie etykiety nowym produktom.

Innym przykładem zastosowania może być model wykrywający anomalie, błędy i braki w zbiorach danych. W ramach uczenia nadzorowanego model nauczy się rozpoznawać poprawne etykiety produktów. Na przykład, umie stwierdzić, że dany kod ACT jest niepoprawny bo nie zaczyna od litery, jak przewiduje przyjęty standard.

4.3/4. Feature Engineering i EDA

Pierwszym krokiem analizy jest zapoznanie się ze zbiorem danych oraz charakterystyką poszczególnych cech. Większość nazw kolumn jest na tyle opisowa, że pozwala na dobre zrozumienie rodzaju danych i informacji jakie przekazują. Zestaw danych zawiera następujące kolumny:

- *Identyfikator Produktu Leczniczego*
- *Nazwa Produktu Leczniczego* – handlowa (rynkowa) nazwa leku
- *Nazwa powszechnie stosowana* – międzynarodowa nazwa substancji czynnej leku (np. Paracetamolum, Ibuprofenum)
- *Rodzaj preparatu* – kolumna binarna: ['Ludzki', 'Weterynaryjny']
- *Zakaz stosowania u zwierząt* – kolumna binarna: ['Tak', nan]
- *Nazwa poprzednia produktu*
- *Droga podania-Gatunek-Tkanka-Okres karencji* – jak lek może być podawany, do jakiego gatunku zwierząt, na jaką tkankę i czas karencji

- *Moc* – zawartość substancji czynnej w leku (np. 1mg/g)
- *Postać farmaceutyczna* – (np. tabletki, krem, roztwór)
- *Typ procedury* – sposób rejestracji leku (procedury stosowane w UE)
- *Numer pozwolenia* – oficjalny numer pozwolenia na dopuszczenie do obrotu
- *Ważność pozwolenia* – data ważności pozwolenia
- *Kod ATC* – klasyfikacja terapeutyczno-chemiczna leku wg systemu WHO
- *Podmiot odpowiedzialny* – firma odpowiedzialna za lek (producent lub/i dystrybutor)
- *Opakowanie* – Informacje o opakowaniu (zawiera informacje o ilość tabletek, objętość syropu.)
- *Substancja czynna* – związek odpowiedzialny za działanie terapeutyczne leku
- *Nazwa wytwórcy* – nazwa producenta leku
- *Kraj wytwórcy*
- *Nazwa importera* – firma importująca lek
- *Kraj importera*
- *Nazwa wytwórcy/importera* – połączenie informacji z powyżej
- *Kraj wytwórcy/importera*
- *Podmiot odpowiedzialny w kraju eksportu* – firma odpowiedzialna za sprowadzany zza granicy lek
- *Kraj eksportu* – kraj, z którego lek jest eksportowany do Polski.
- *Podstawa prawna wniosku* – podstawa prawna, na jakiej dokonano rejestracji leku.
- *Ulotka* – link do ulotki dla pacjenta
- *Charakterystyka* – link do Charakterystyki Produktu Leczniczego
- *Etykieto-ulotka* – połączenie dwóch powyżej
- *Ulotka importu równoległego* – link do ulotki
- *Etykieto-ulotka importu równoległego* – połączenie etykiety i ulotki
- *Oznakowanie opakowań importu równoległego* – link do oznakowani
- *Materiały edukacyjne dla osoby wykonującej zawód medyczny* – linki
- *Materiały edukacyjne dla pacjenta* – linki

Ostatnie osiem kolumn zawiera wyłącznie linki URL, które nie wnoszą żadnych istotnych informacji i będą przeszkadzać w dalszej analizie. W związku z tym zostaną one od razu usunięte.

Drugim krokiem analizy jest sprawdzanie brakujących wartości w poszczególnych cechach oraz EDA. Należy zauważyć, że zbiór danych zawiera dwa typy wartości brakujących: ”-” oraz NaN. Dla ułatwienia dalszej analizy, wszystkie wystąpienia znaku ”-” zostały zamienione na wartości NaN. Po ujednoliceniu

brakujących danych możemy przystąpić do ich zliczania oraz określenia, jaki procent całego zbioru stanowią.

	Sum	Avg	Procent
Identyfikator Produktu Leczniczego	0	0.000000	0.00
Nazwa Produktu Leczniczego	0	0.000000	0.00
Nazwa powszechnie stosowana	19	0.000852	0.09
Rodzaj preparatu	0	0.000000	0.00
Zakaz stosowania u zwierząt	22146	0.992872	99.29
Nazwa poprzednia produktu	21000	0.941493	94.15
Droga podania - Gatunek - Tkanka - Okres karencji	57	0.002555	0.26
Moc	876	0.039274	3.93
Postać farmaceutyczna	0	0.000000	0.00
Typ procedury	0	0.000000	0.00
Numer pozwolenia	3629	0.162699	16.27
Ważność pozwolenia	3969	0.177942	17.79
Kod ATC	1124	0.050392	5.04
Podmiot odpowiedzialny	10	0.000448	0.04
Opakowanie	12	0.000538	0.05
Substancja czynna	1187	0.053217	5.32
Nazwa wytwórcy	7596	0.340551	34.06
Kraj wytwórcy	7596	0.340551	34.06
Nazwa importera	20620	0.924456	92.45
Kraj importera	20620	0.924456	92.45
Nazwa wytwórcy/importera	4346	0.194844	19.48
Kraj wytwórcy/importera	4346	0.194844	19.48
Podmiot odpowiedzialny w kraju eksportu	17971	0.805694	80.57
Kraj eksportu	17971	0.805694	80.57
Podstawa prawna wniosku	8627	0.386774	38.68

Tabelka 1. Zaliczenie wartości brakujących

Pierwszą cechą w Tabeli 1, dla której występują braki danych, jest *Nazwa powszechnie stosowana*. Po bliższej analizie zauważono, że braki w tej kolumnie są spójne w obrębie tej samej *Nazwy Produktu Leczniczego* — jeżeli jedna z wersji produktu nie posiada tej informacji, to dotyczy to wszystkich rekordów o tej samej nazwie (zob. Tabela 2). Może to wynikać z niekompletnego wpisu albo faktu, że

dany produkt nie zawiera jednej aktywnej substancji czynnej, lecz jest preparatem złożonym. Braki te można zaklasyfikować jako *MAR (Missing at Random)*. Jako, że stanowią bardzo mały procent danych, zostały one usunięte z danych.

	Identyfikator Produktu Leczniczego	Nazwa Produktu Leczniczego	Nazwa powszechnie stosowana	Rodzaj preparatu	Zakaz stosowania u zwierząt	Nazwa poprzednia produktu
4	100000089	Diprobase	NaN	Ludzki	NaN	NaN
1609	100082704	Diprobase	NaN	Ludzki	NaN	NaN
13094	100390883	Diprobase	NaN	Ludzki	NaN	NaN
13829	100400498	Diprobase	NaN	Ludzki	NaN	NaN

Tabelka 2. Tabelka dla leku „Diprobase"

Cecha *Zakaz stosowania u zwierząt* zawiera w przybliżeniu 99% brakujących wartości. Sprawdzenie unikalnych wartości wykazało, że cecha przyjmuję tylko dwie wartości: ['Tak', nan]. Ponieważ brak danych najprawdopodobniej oznacza brak zakazu stosowania, brakujące wartości zostały zastąpione wartością *Nie*. Wskazuje to, że wartości brakujące należą do typu *MNAR (Missing Not at Random)*, ponieważ ich nieobecność wynika z określonego powodu — braku zakazu.

Podobna sytuacja dotyczy cechy *Nazwa poprzednia produktu*, gdzie brakujące dane mogą wynikać z faktu, że lek nie zmienił swojej nazwy , a więc wcześniejsza nazwa nie istnieje. Dane te również można zaklasyfikować jako typ *MNAR*. Braki zostały zapełnione poprzez wartość *None*.

Dla cechy *Droga podania - Gatunek - Tkanka - Okres karencji* wartości brakujące są typu *MCAR (Missing Completely at Random)*, ponieważ nie zaobserwowano żadnych wyraźnych zależności ani przyczyn, które mogłyby tłumaczyć ich nieobecność. Pomimo, że procent braków dla tej cechy jest dość mały, zdecydowano się nie usuwać tych rekordów, ponieważ możliwe było ich uzupełnienie w prosty i logiczny sposób.

Zauważono istotną zależność między analizowaną cechą a *Postacią farmaceutyczną*. Na tej podstawie utworzono zmienną pomocniczą, zawierającą najczęściej występującą wartość w kolumnie *Droga podania – Gatunek – Tkanka – Okres karencji* dla każdej postaci farmaceutycznej. Braki zostały uzupełnione na podstawie tej zmiennej. Po ponownym sprawdzeniu wartości brakujących została

tylko jedna wartość , którą – po sprawdzeniu *Postaci farmaceutycznej* – została uzupełniona odpowiednią cechą. (patrz: Tabela 3).

	Identyfikator Produktu Leczniczego	Nazwa Produktu Leczniczego	Nazwa powszechnie stosowana	Droga podania - Gatunek - Tkanka - Okres karencji	Postać farmaceutyczna
4005	100164566	Serevent	Salmeterolum	NaN	Aerozol wziewny, zawiesina

Tabelka 3. Ostania brakująca wartość po uzupełnieniu danych za pomocą najczęściej występującej wartości

```
.. code:: ipython3 data['Droga podania - Gatunek - Tkanka - Okres
karencji'] = data['Droga podania - Gatunek - Tkanka - Okres
karencji'].fillna("wziewna")
```

Cechy *Numer pozwolenia* i *Ważność pozwolenia* mają dość znaczący odsetek wartości brakujących. Przyjrzenie się danym wykazało, że wartości tych cech nie są w pełni współzależne, gdyż w niektórych przypadkach brak jest daty ważności pomimo obecności numeru pozwolenia. Wiadomo, że nie jest to spowodowane bezterminowym pozwoleniem, gdyż istnieje już taka etykieta w zbiorze. Zdarzają się również sytuacje odwrotne, gdzie występuje data ważności, ale brakuje numeru. Dla uproszczenia i ograniczenia kardynalności dla obu cech, brakujące dane zostały zastąpione wartością *Unknown*. Na podstawie charakteru braków można powiedzieć, że mają one charakter *MAR (Missing at Random)*.

Cechę *Moc* charakteryzuje niski odsetek brakujących wartości. Aby uniknąć wprowadzania dodatkowej etykiety, zdecydowano się na usunięcie wierszy zawierających braki. Brak wartości NaN lub etykiety dla niej zastępczej w kolumnie będzie przydatne przy uzupełnianiu innej cechy.

Dla następujących cech: *Kod ATC*, *Podmiot odpowiedzialny* i *Opakowanie* nie udało się znaleźć zależności między brakującymi wartościami, a innymi zmiennymi. Brak danych wydaje się losowy i bez wyraźnej przyczyny, co sugeruje, że są one typu *MCAR (Missing Completely at Random).* Jako, że brakujące wartości stanowią mały procent danych zostaną one usunięte ze zbioru.

Kolejną analizowaną cechą jest *Substancja czynna*, której wartości brakujące można stosunkowo łatwo uzupełnić, wykorzystując informacje zawarte w kolumnach *Nazwa powszechnie stosowana* oraz *Moc*. Po przyjrzeniu się jak wyglądają wartości tej cechy, można zauważyć, że w większości przypadków wartości *Substancji czynnej* stanowi kombinacje tych dwóch cech (patrz tabela 4).

Na tej podstawie brakujące wartości zostały uzupełnione łącząc wartości z kolumn *Nazwa powszechnie stosowana* i *Moc.*

	Nazwa powszechnie stosowana	Moc	Substancja czynna
0	Acidum zoledronicum	4 mg/5 ml	Acidum zoledronicum 4 mg/5 ml
1	Mometasoni furoas	1 mg/g	Mometasoni furoas 1 mg/g
2	Naproxenum natricum	275 mg	Naproxenum natricum 275 mg
3	Naproxenum natricum	550 mg	Naproxenum natricum 550 mg
5	Amlodipinum	10 mg	Amlodipini besilas 10 mg
...	...	...	...
22299	Pegfilgrastimum	6 mg	Pegfilgrastimum 6 mg
22301	Afliberceptum	40 mg/ml	Afliberceptum 40 mg/ml
22302	Eltrombopagum	25 mg	Eltrombopagum 25 mg
22303	Eltrombopagum	50 mg	Eltrombopagum 50 mg
22304	Eltrombopagum	75 mg	Eltrombopagum 75 mg

Tabelka 4. Zależność między *Nazwa powszechnie stosowana*, *Moc* i *Substancja czynna*

W przypadku pozostałych cech: *Nazwa wytwórcy, Kraj wytwórcy*, *Nazwa importera*, *Kraj importera*, *Nazwa wytwórcy/importera*, *Kraj wytwórcy/importera*, *Podmiot odpowiedzialny w kraju eksportu, Kraj eksportu, Podstawa prawna wniosku* widnieje duży odsetek swoich danych jako wartości brakujące. Brak tych wartości jest powiązany z różnymi aspektami dotyczącymi produkcji, importu, rejestracji oraz nadzoru nad danym produktem. Ze względu na ich dużą skalę, brakujące wartości zostały zamienione na wartość *Unknown*.

Trzecim krokiem analizy będzie zbadanie rozkładu danych. Ponieważ wszystkie zmienne w zbiorze mają charakter kategoryczny, w pierwszej kolejności zostanie określona liczba unikalnych wartości występujących w każdej z nich.

```
.. code:: ipython3
    data.shape
.. parsed-literal::
    (20816, 25)
```

	Liczba unikalnych wartości
Identyfikator Produktu Leczniczego	20816
Nazwa Produktu Leczniczego	10124
Nazwa powszechnie stosowana	3434
Rodzaj preparatu	2
Zakaz stosowania u zwierząt	2
Nazwa poprzednia produktu	840
Droga podania - Gatunek - Tkanka - Okres karencji	1440
Moc	3739
Postać farmaceutyczna	468
Typ procedury	5
Numer pozwolenia	17042
Ważność pozwolenia	1875
Kod ATC	2726
Podmiot odpowiedzialny	1032
Opakowanie	20816
Substancja czynna	9572
Nazwa wytwórcy	2618
Kraj wytwórcy	755
Nazwa importera	450
Kraj importera	219
Nazwa wytwórcy /importera	3277
Kraj wytwórcy/importera	997
Podmiot odpowiedzialny w kraju eksportu	904
Kraj eksportu	25
Podstawa prawna wniosku	35

Tabelka 5. Liczba unikalnych wartości dla każdej zmiennej

W przypadku zmiennych zawierających dużą liczbę unikalnych kategorii, w celu zachowania czytelności wykresów słupkowych, ograniczono liczbę

prezentowanych wartości do 15 najczęściej występujących. Poniżej znajdują się wykresy dla wszystkich zmiennych poza *Identyfikator Produktu Leczniczego* oraz *Opakowanie*, które zostały pominięte, ponieważ każda ich wartość jest unikalna i odpowiada pojedynczemu rekordowi w zbiorze danych.

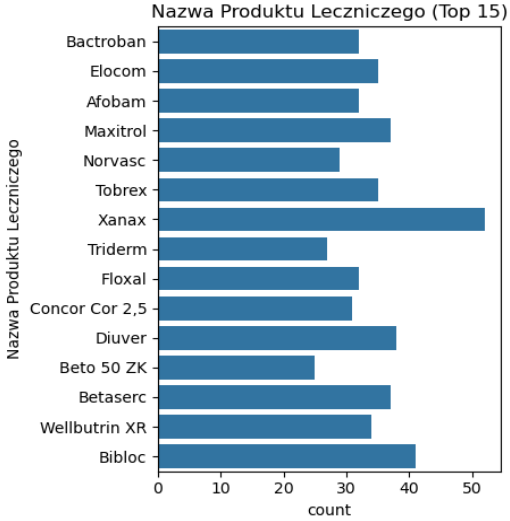

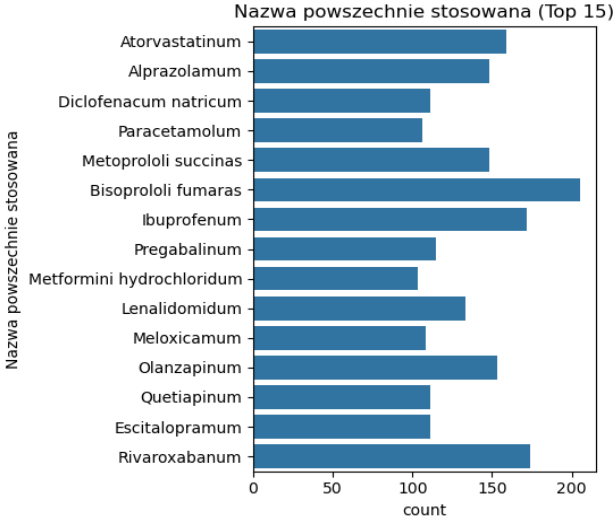

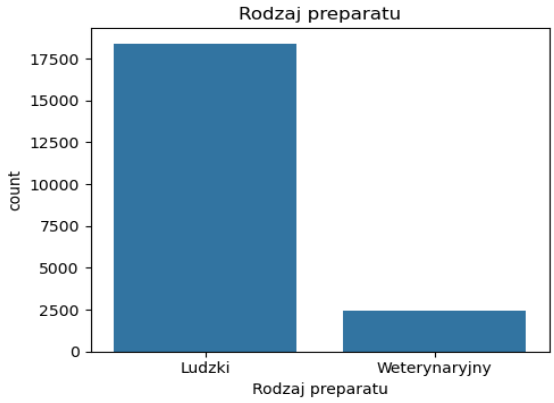

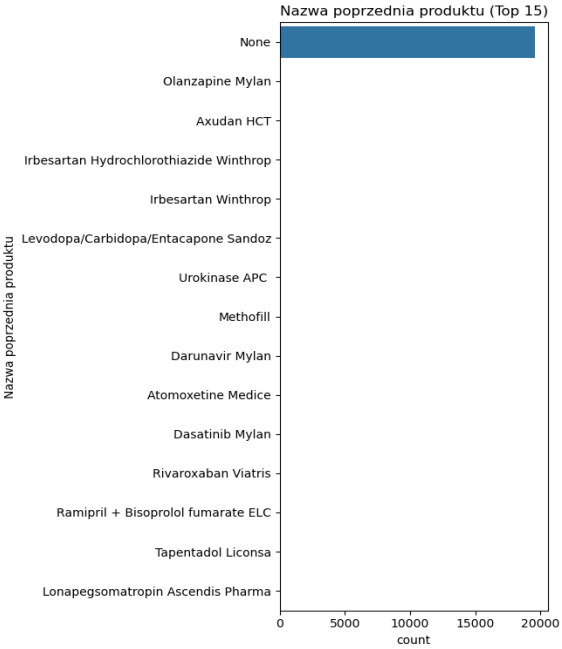

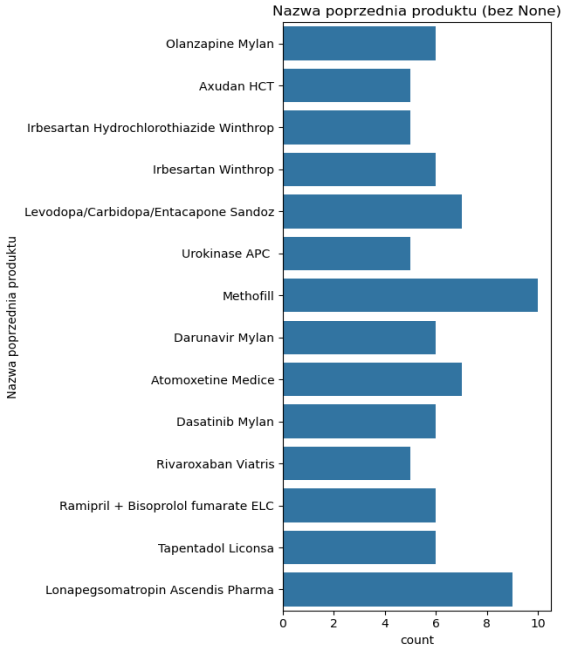

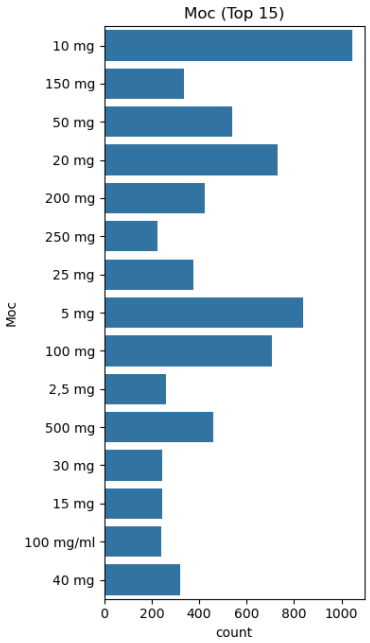
Moc (Top 15)
10 mg
150 mg
50 mg
20 mg
200 mg
250 mg
25 mg
5 mg
100 mg
2,5 mg
500 mg
30 mg
15 mg
100 mg/ml
40 mg
Moc
0
200
400
600
800
1000
count

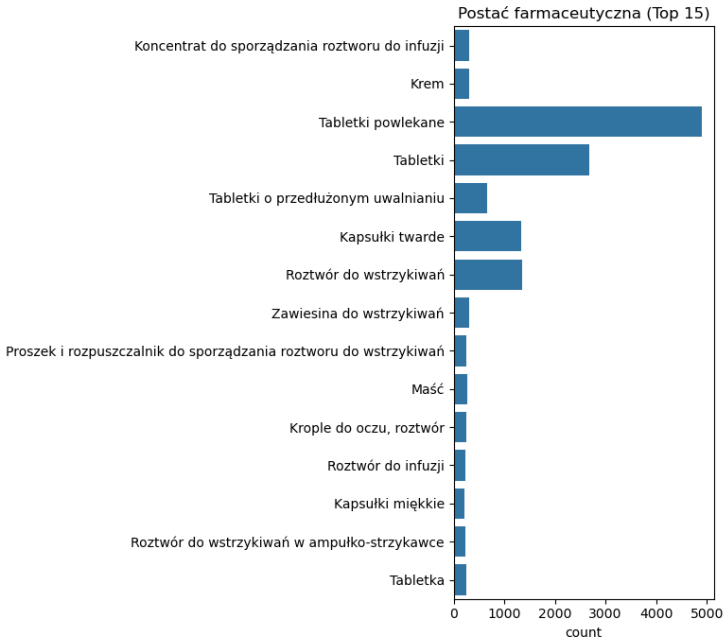
Postać farmaceutyczna (Top 15)
Koncentrat do sporządzania roztworu do infuzji
Krem
Tabletki powlekane
Tabletki
Tabletki o przedłużonym uwalnianiu
Kapsułki twarde
Roztwór do wstrzykiwań
Zawiesina do wstrzykiwań
Proszek i rozpuszczalnik do sporządzania roztworu do wstrzykiwań
Maść
Krople do oczu, roztwór
Roztwór do infuzji
Kapsułki miękkie
Roztwór do wstrzykiwań w ampułko-strzykawce
Tabletka
Postać farmaceutyczna
0
1000
2000
3000
4000
5000
count

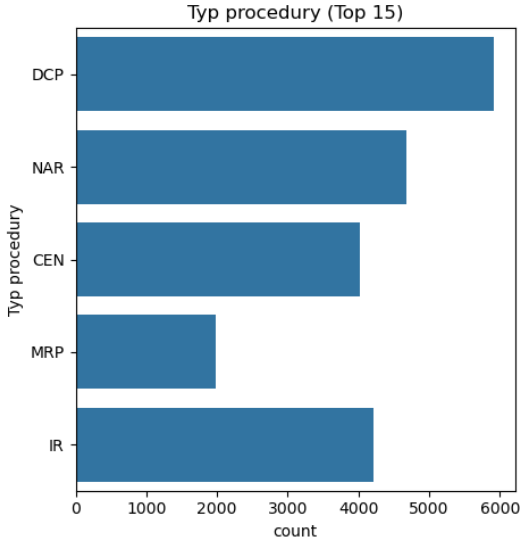
Typ procedury (Top 15)
DCP
NAR
CEN
MRP
IR
Typ procedury
0
1000
2000
3000
4000
5000
6000
count

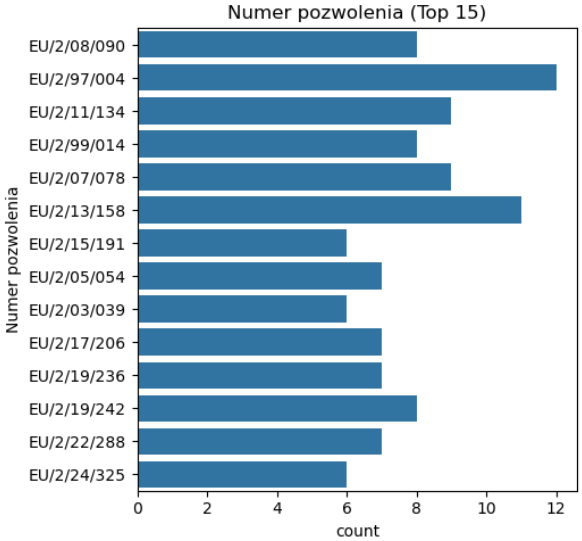
Numer pozwolenia (Top 15)
EU/2/08/090
EU/2/97/004
EU/2/11/134
EU/2/99/014
EU/2/07/078
EU/2/13/158
EU/2/15/191
EU/2/05/054
EU/2/03/039
EU/2/17/206
EU/2/19/236
EU/2/19/242
EU/2/22/288
EU/2/24/325
Numer pozwolenia
0
2
4
6
8
10
12
count

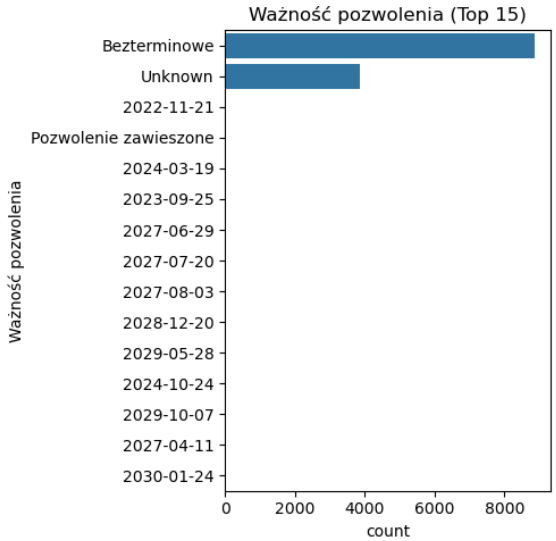
Ważność pozwolenia (Top 15)
Bezterminowe
Unknown
2022-11-21
Pozwolenie zawieszone
2024-03-19
2023-09-25
2027-06-29
2027-07-20
2027-08-03
2028-12-20
2029-05-28
2024-10-24
2029-10-07
2027-04-11
2030-01-24
Ważność pozwolenia
0
2000
4000
6000
8000
count

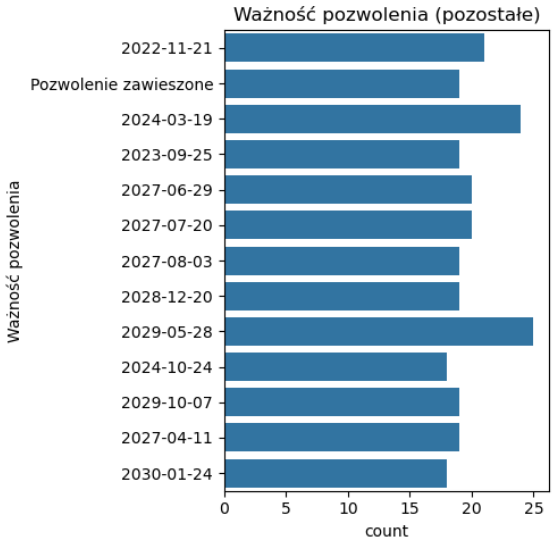
Ważność pozwolenia (pozostałe)
2022-11-21
Pozwolenie zawieszone
2024-03-19
2023-09-25
2027-06-29
2027-07-20
2027-08-03
2028-12-20
2029-05-28
2024-10-24
2029-10-07
2027-04-11
2030-01-24
Ważność pozwolenia
0
5
10
15
20
25
count

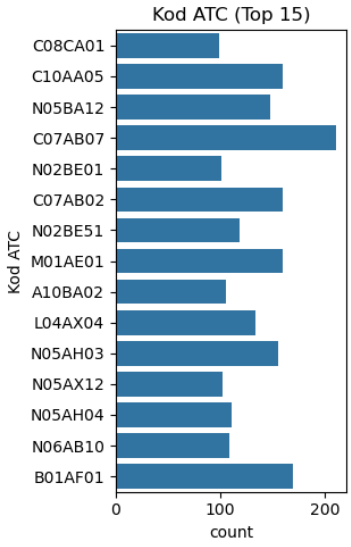
Kod ATC (Top 15)
C08CA01
C10AA05
N05BA12
C07AB07
N02BE01
C07AB02
N02BE51
M01AE01
A10BA02
L04AX04
N05AH03
N05AX12
N05AH04
N06AB10
B01AF01
Kod ATC
0
100
200
count

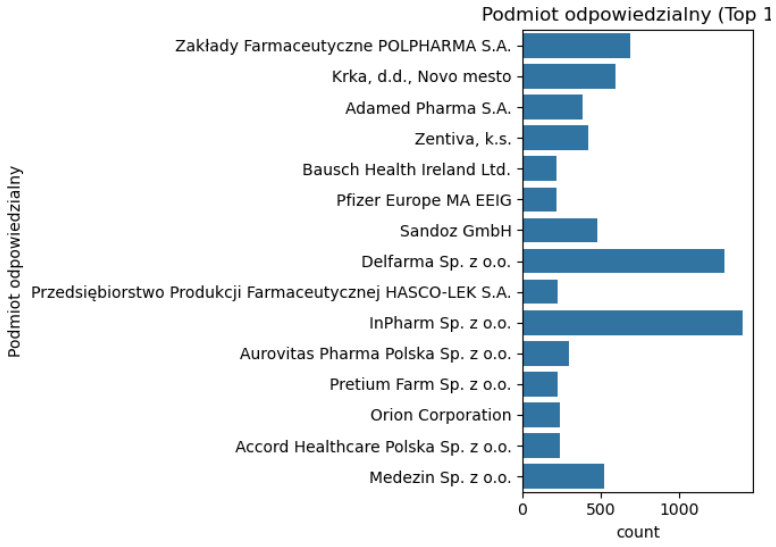
Podmiot odpowiedzialny (Top 1
Zakłady Farmaceutyczne POLPHARMA S.A.
Krka, d.d., Novo mesto
Adamed Pharma S.A.
Zentiva, k.s.
Bausch Health Ireland Ltd.
Pfizer Europe MA EEIG
Sandoz GmbH
Delfarma Sp. z o.o.
Przedsiębiorstwo Produkcji Farmaceutycznej HASCO-LEK S.A.
InPharm Sp. z o.o.
Aurovitas Pharma Polska Sp. z o.o.
Pretium Farm Sp. z o.o.
Orion Corporation
Accord Healthcare Polska Sp. z o.o.
Medezin Sp. z o.o.
Podmiot odpowiedzialny
0
500
1000
count

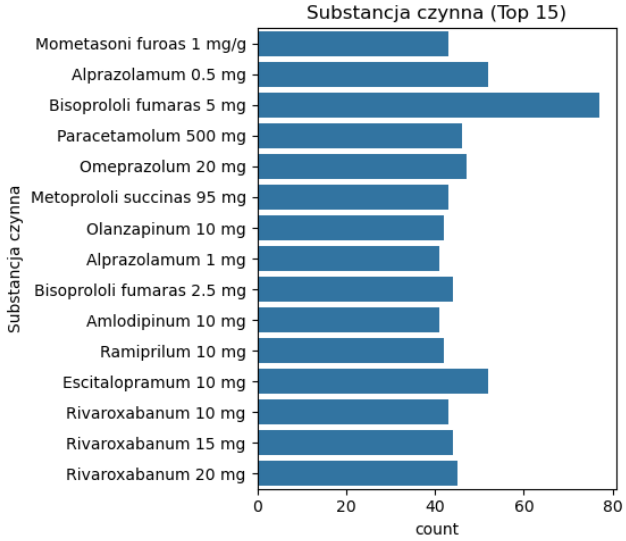
Substancja czynna (Top 15)
Mometasoni furoas 1 mg/g
Alprazolamum 0.5 mg
Bisoprololi fumaras 5 mg
Paracetamolum 500 mg
Omeprazolum 20 mg
Metoprololi succinas 95 mg
Olanzapinum 10 mg
Alprazolamum 1 mg
Bisoprololi fumaras 2.5 mg
Amlodipinum 10 mg
Ramiprilum 10 mg
Escitalopramum 10 mg
Rivaroxabanum 10 mg
Rivaroxabanum 15 mg
Rivaroxabanum 20 mg
Substancja czynna
0
20
40
60
80
count

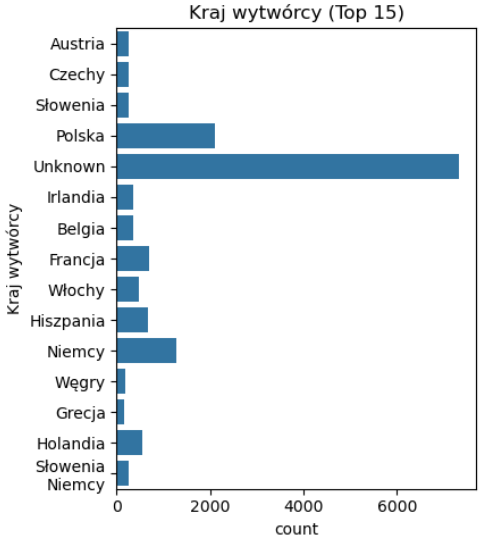
Kraj wytwórcy (Top 15)
Austria
Czechy
Słowenia
Polska
Unknown
Irlandia
Belgia
Francja
Włochy
Hiszpania
Niemcy
Węgry
Grecja
Holandia
Słowenia
Niemcy
Kraj wytwórcy
0
2000
4000
6000
count

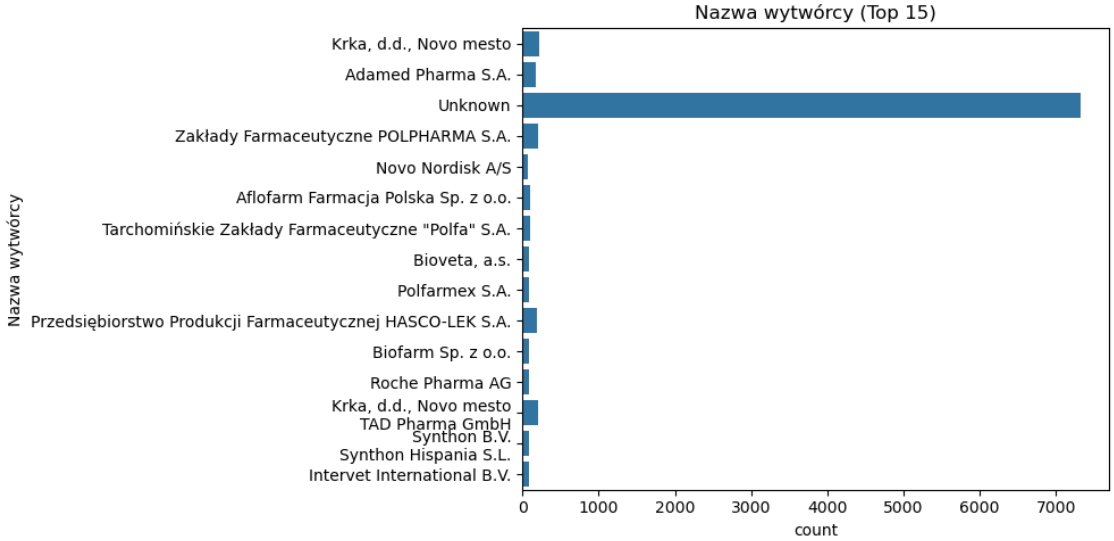
Nazwa wytwórcy (Top 15)
Krka, d.d., Novo mesto
Adamed Pharma S.A.
Unknown
Zakłady Farmaceutyczne POLPHARMA S.A.
Novo Nordisk A/S
Aflofarm Farmacja Polska Sp. z o.o.
Tarchomińskie Zakłady Farmaceutyczne "Polfa" S.A.
Bioveta, a.s.
Polfarmex S.A.
Przedsiębiorstwo Produkcji Farmaceutycznej HASCO-LEK S.A.
Biofarm Sp. z o.o.
Roche Pharma AG
Krka, d.d., Novo mesto
TAD Pharma GmbH
Synthon B.V.
Synthon Hispania S.L.
Intervet International B.V.
Nazwa wytwórcy
0
1000
2000
3000
4000
5000
6000
7000
count

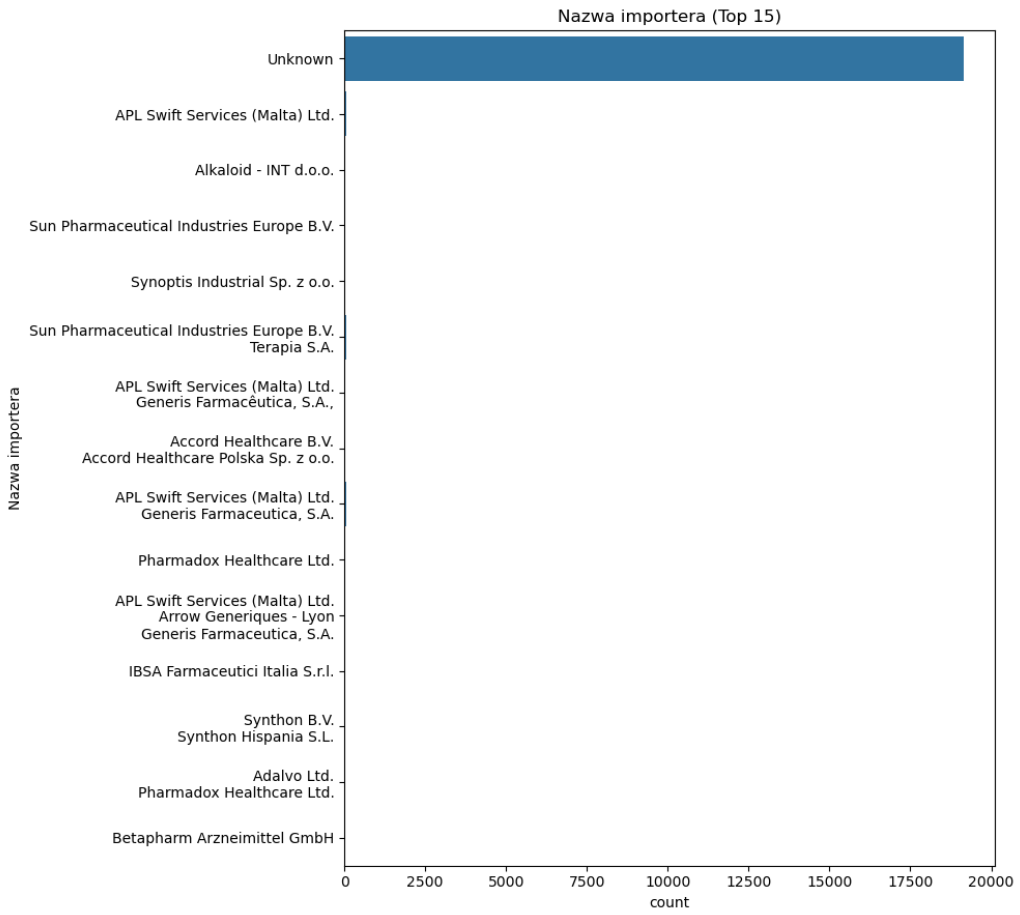
Nazwa importera (Top 15)
Unknown
APL Swift Services (Malta) Ltd.
Alkaloid - INT d.o.o.
Sun Pharmaceutical Industries Europe B.V.
Synoptis Industrial Sp. z o.o.
Sun Pharmaceutical Industries Europe B.V.
Terapia S.A.
APL Swift Services (Malta) Ltd.
Generis Farmacêutica, S.A.,
Accord Healthcare B.V.
Accord Healthcare Polska Sp. z o.o.
APL Swift Services (Malta) Ltd.
Generis Farmaceutica, S.A.
Pharmadox Healthcare Ltd.
APL Swift Services (Malta) Ltd.
Arrow Generiques - Lyon
Generis Farmaceutica, S.A.
IBSA Farmaceutici Italia S.r.l.
Synthon B.V.
Synthon Hispania S.L.
Adalvo Ltd.
Pharmadox Healthcare Ltd.
Betapharm Arzneimittel GmbH
Nazwa importera
0
2500
5000
7500
10000
12500
15000
17500
20000
count

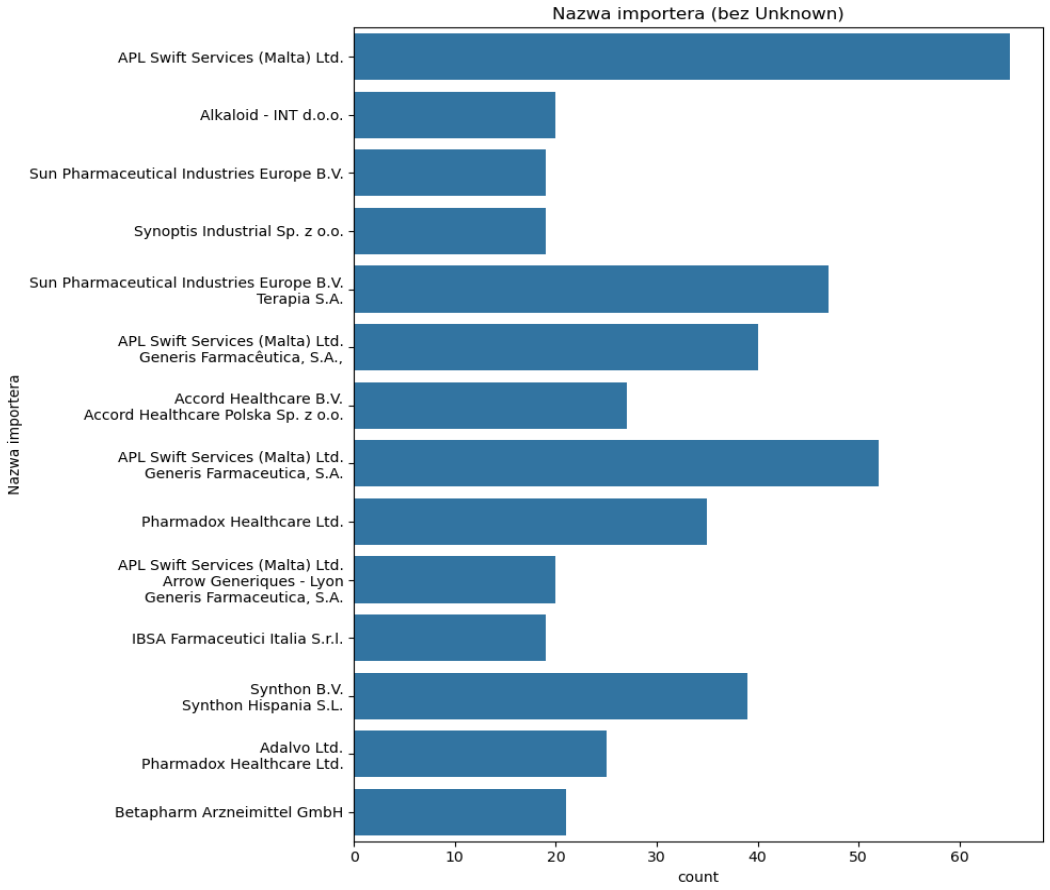
Nazwa importera (bez Unknown)
APL Swift Services (Malta) Ltd.
Alkaloid - INT d.o.o.
Sun Pharmaceutical Industries Europe B.V.
Synoptis Industrial Sp. z o.o.
Sun Pharmaceutical Industries Europe B.V.
Terapia S.A.
APL Swift Services (Malta) Ltd.
Generis Farmacêutica, S.A.,
Accord Healthcare B.V.
Accord Healthcare Polska Sp. z o.o.
APL Swift Services (Malta) Ltd.
Generis Farmaceutica, S.A.
Pharmadox Healthcare Ltd.
APL Swift Services (Malta) Ltd.
Arrow Generiques - Lyon
Generis Farmaceutica, S.A.
IBSA Farmaceutici Italia S.r.l.
Synthon B.V.
Synthon Hispania S.L.
Adalvo Ltd.
Pharmadox Healthcare Ltd.
Betapharm Arzneimittel GmbH
Nazwa importera
0
10
20
30
40
50
60
count

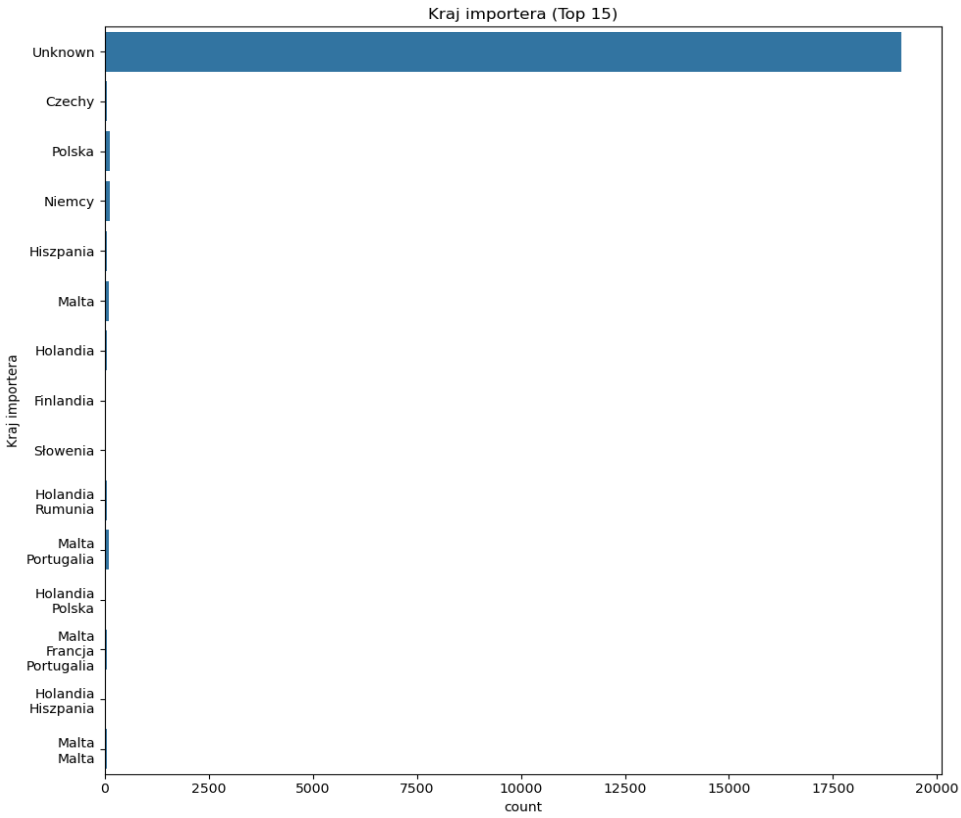
Kraj importera (Top 15)
Unknown
Czechy
Polska
Niemcy
Hiszpania
Malta
Holandia
Finlandia
Słowenia
Holandia
Rumunia
Malta
Portugalia
Holandia
Polska
Malta
Francja
Portugalia
Holandia
Hiszpania
Malta
Malta
Kraj importera
0
2500
5000
7500
10000
12500
15000
17500
20000
count

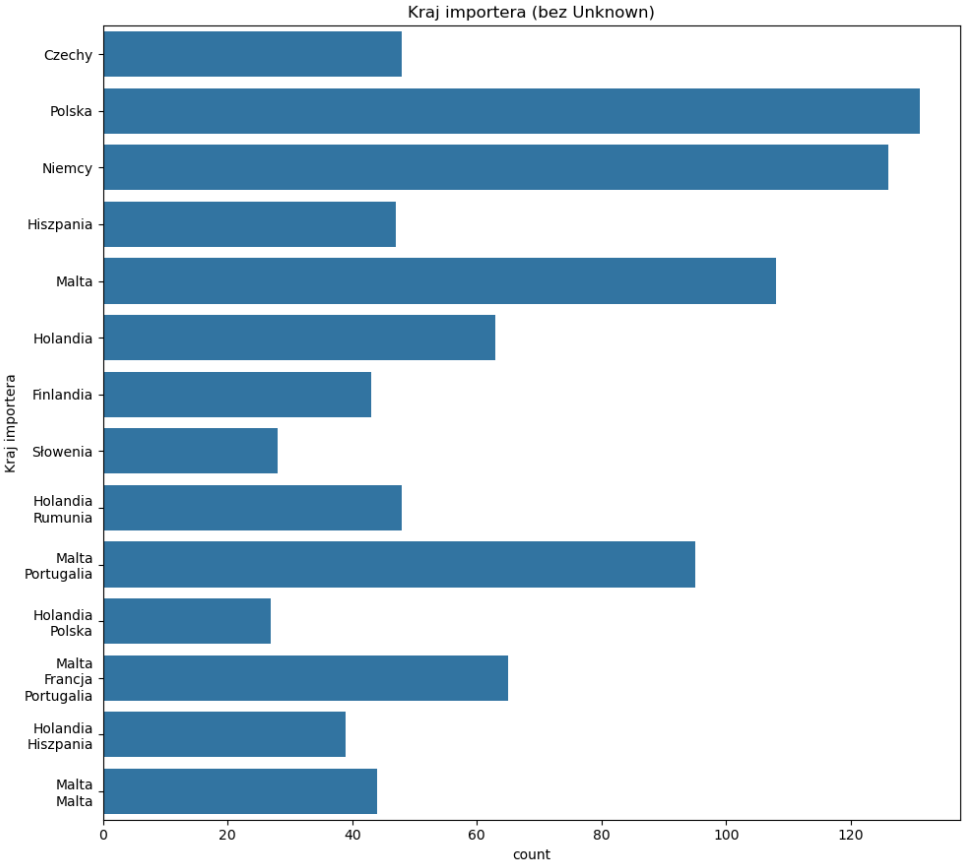
Kraj importera (bez Unknown)
Czechy
Polska
Niemcy
Hiszpania
Malta
Holandia
Finlandia
Słowenia
Holandia
Rumunia
Malta
Portugalia
Holandia
Polska
Malta
Francja
Portugalia
Holandia
Hiszpania
Malta
Malta
Kraj importera
0
20
40
60
80
100
120
count

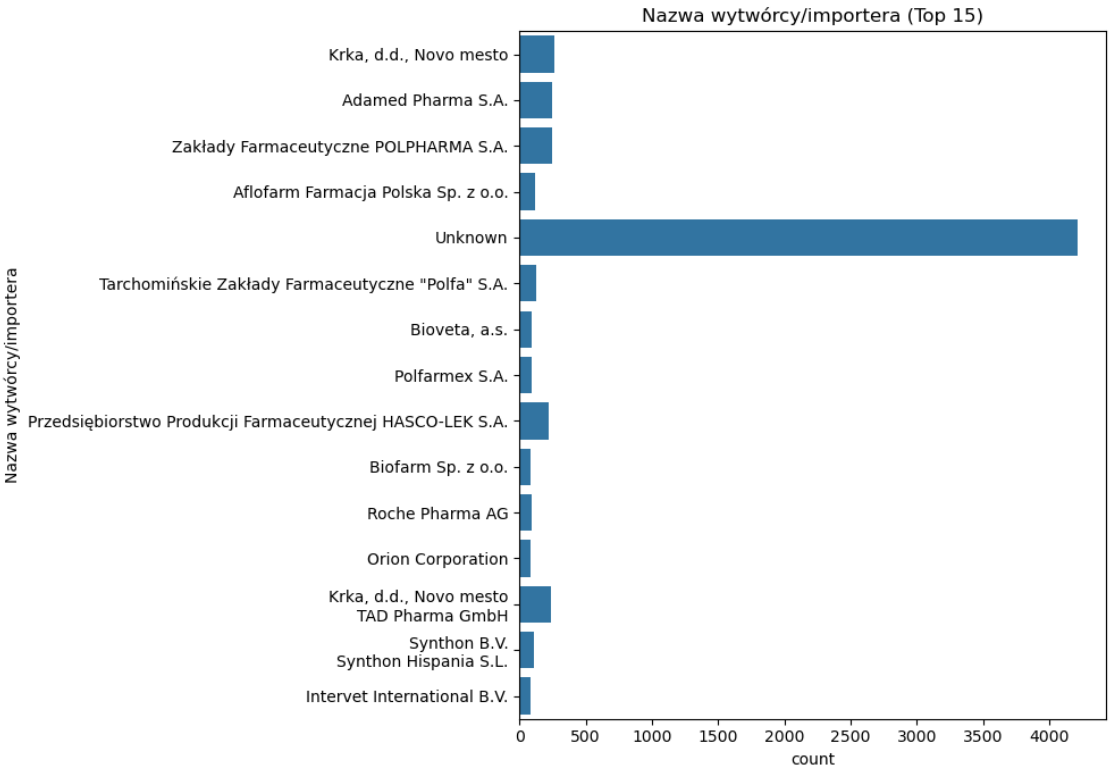
Nazwa wytwórcy/importera (Top 15)
Nazwa wytwórcy/importera
Krka, d.d., Novo mesto
Adamed Pharma S.A.
Zakłady Farmaceutyczne POLPHARMA S.A.
Aflofarm Farmacja Polska Sp. z o.o.
Unknown
Tarchomińskie Zakłady Farmaceutyczne "Polfa" S.A.
Bioveta, a.s.
Polfarmex S.A.
Przedsiębiorstwo Produkcji Farmaceutycznej HASCO-LEK S.A.
Biofarm Sp. z o.o.
Roche Pharma AG
Orion Corporation
Krka, d.d., Novo mesto
TAD Pharma GmbH
Synthon B.V.
Synthon Hispania S.L.
Intervet International B.V.
0
500
1000
1500
2000
2500
3000
3500
4000
count

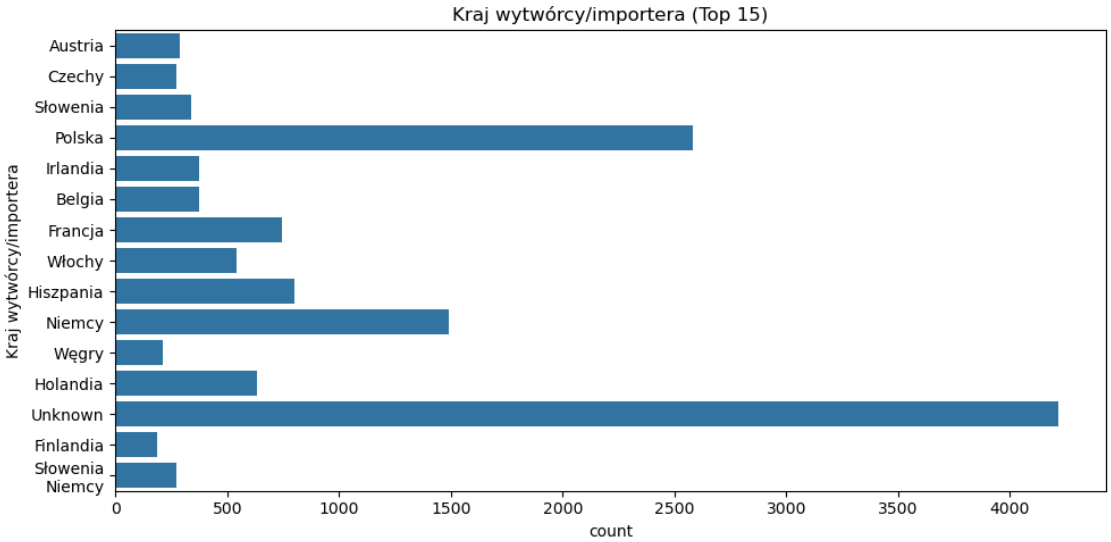
Kraj wytwórcy/importera (Top 15)
Kraj wytwórcy/importera
Austria
Czechy
Słowenia
Polska
Irlandia
Belgia
Francja
Włochy
Hiszpania
Niemcy
Węgry
Holandia
Unknown
Finlandia
Słowenia
Niemcy
0
500
1000
1500
2000
2500
3000
3500
4000
count

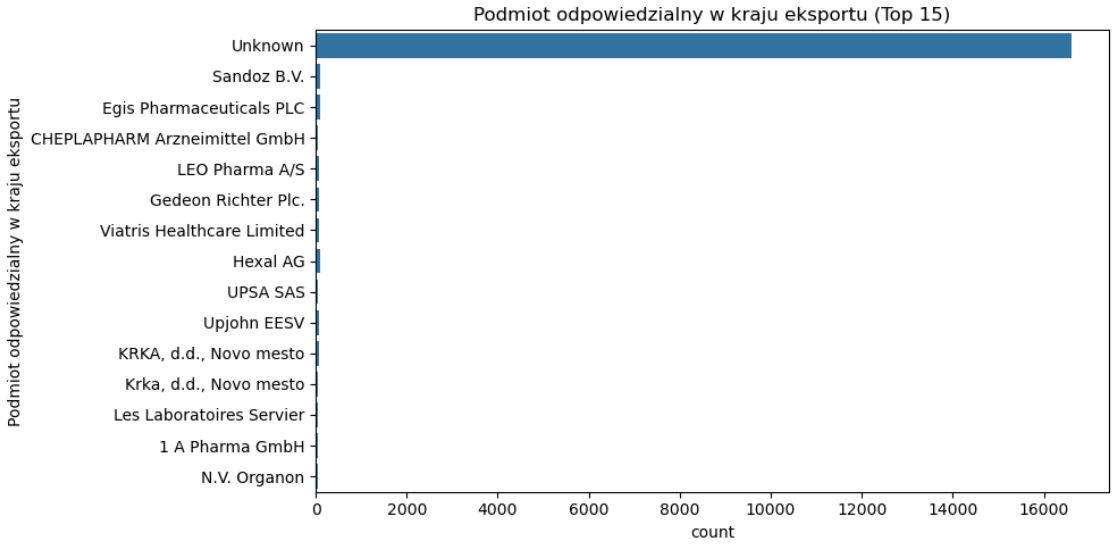
Podmiot odpowiedzialny w kraju eksportu (Top 15)
Podmiot odpowiedzialny w kraju eksportu
Unknown
Sandoz B.V.
Egis Pharmaceuticals PLC
CHEPLAPHARM Arzneimittel GmbH
LEO Pharma A/S
Gedeon Richter Plc.
Viatris Healthcare Limited
Hexal AG
UPSA SAS
Upjohn EESV
KRKA, d.d., Novo mesto
Krka, d.d., Novo mesto
Les Laboratoires Servier
1 A Pharma GmbH
N.V. Organon
0
2000
4000
6000
8000
10000
12000
14000
16000
count

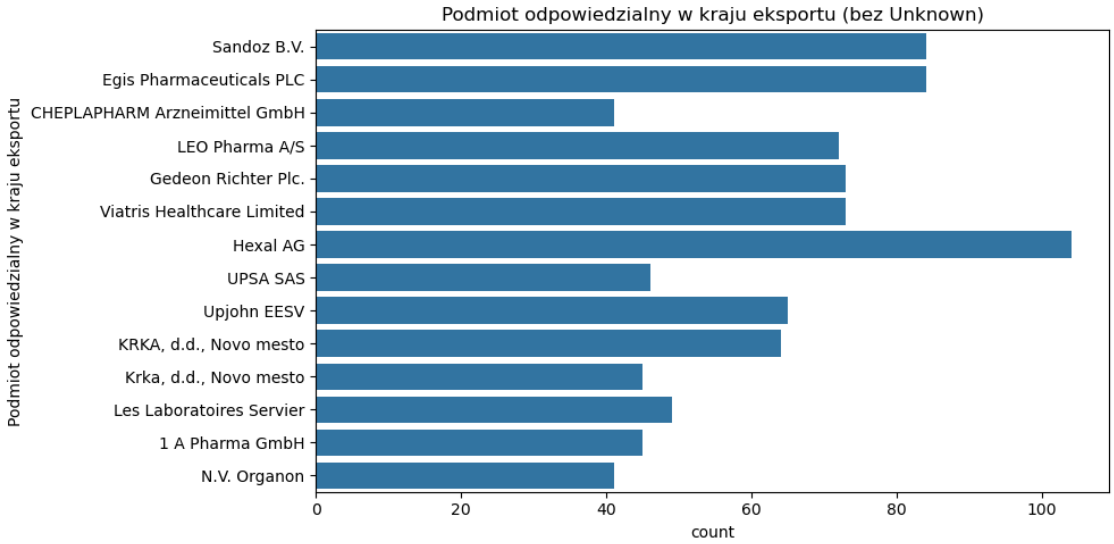
Podmiot odpowiedzialny w kraju eksportu (bez Unknown)
Podmiot odpowiedzialny w kraju eksportu
Sandoz B.V.
Egis Pharmaceuticals PLC
CHEPLAPHARM Arzneimittel GmbH
LEO Pharma A/S
Gedeon Richter Plc.
Viatris Healthcare Limited
Hexal AG
UPSA SAS
Upjohn EESV
KRKA, d.d., Novo mesto
Krka, d.d., Novo mesto
Les Laboratoires Servier
1 A Pharma GmbH
N.V. Organon
0
20
40
60
80
100
count

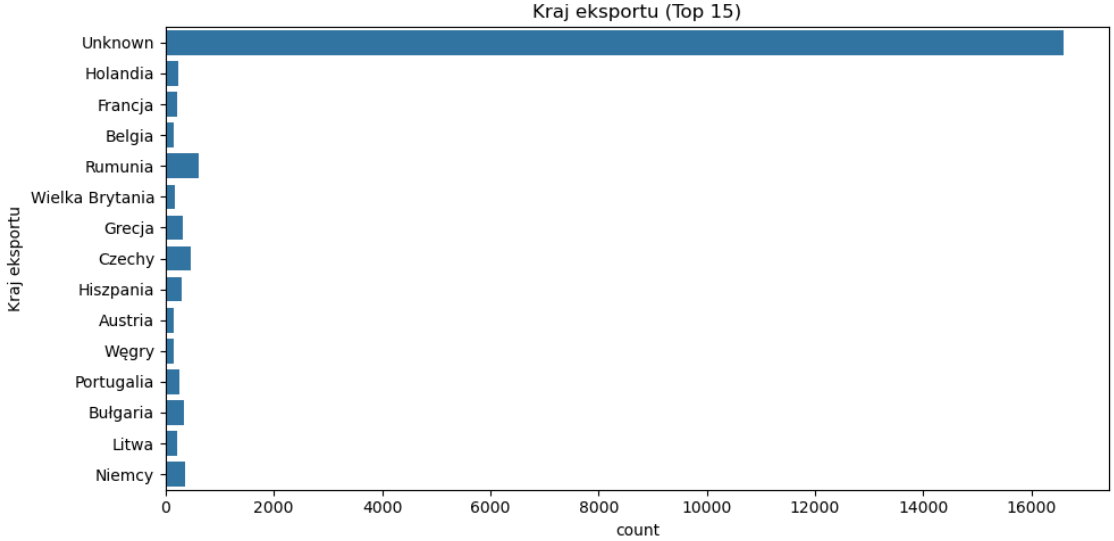
Kraj eksportu (Top 15)
Kraj eksportu
Unknown
Holandia
Francja
Belgia
Rumunia
Wielka Brytania
Grecja
Czechy
Hiszpania
Austria
Węgry
Portugalia
Bułgaria
Litwa
Niemcy
0
2000
4000
6000
8000
10000
12000
14000
16000
count

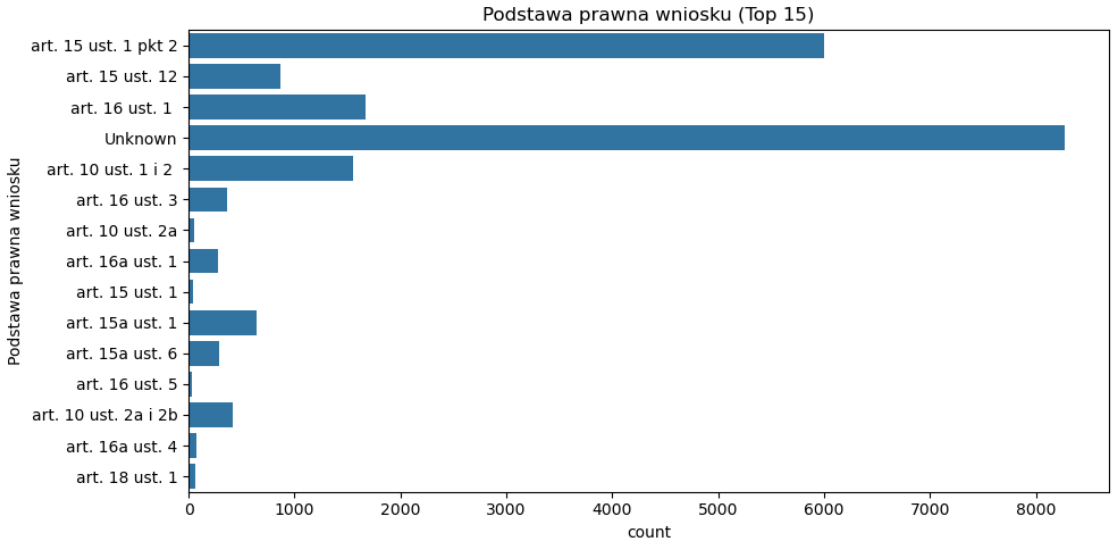

W przypadku niektórych zmiennych zaobserwowano częste występowanie jednej lub dwóch wartości, co uniemożliwiało czytelne przedstawienie pozostałych kategorii na wykresie słupkowym. Dlatego dla tych zmiennych sporządzono dodatkowe wykresy, pomijając dominujące wartości, aby umożliwić analizę i wizualizację reszty rozkładu danych.

Warto zauważyć, że w wielu przypadkach dominującą kategorią były wartości typu *Unknown*, które są kategorią dodaną, aby reprezentować wartości brakujące. Ich obecność w tak dużym natężeniu może znacząco wpływać na interpretację rozkładu i powinna być uwzględniona w dalszej analizie.

Drugą do odnotowania dysproporcją jest nierówność klas dla dwóch zmiennych binarnych: *Rodzaj preparatu* i *Zakaz stosowania u zwierząt*. W większości danych dominuje odpowiednio kategoria '*Ludzki*' i '*Nie*'. Należy to uwzględnić do dalszej analizy.

Dla pozostałych zmiennych kategorycznych rozkład obserwacji pomiędzy kategoriami jest w większości równomierny. Taki rozkład sprzyja prostej analizie oraz może pozytywnie wpływać na działanie modeli predykcyjnych, gdyż zapewnia bardziej zrównoważoną reprezentację każdej z kategorii.

Kolejnym krokiem analizy będzie ograniczenie kardynalności wybranych cech. Nadmierna liczba unikalnych wartości może negatywnie wpływać na jakość modelu. W związku z tym dokonano redukcji liczby etykiet w kolumnach *Droga podania-Gatunek-Tkanka-Okres karencji* oraz *Postać farmaceutyczna*, a zredukowane wartości przypisano do *Droga podania* i *Postać farmaceutyczna RED.*

```
.. code:: ipython3

  columns = data.columns.tolist()

  for col in columns:
      wart = data[col].unique()
      print('Liczba etykiet zmiennej {}: {}'.format(col, len(wart)))


.. parsed-literal::

  Liczba etykiet zmiennej Identyfikator Produktu Leczniczego: 20816
  Liczba etykiet zmiennej Nazwa Produktu Leczniczego: 10124
  Liczba etykiet zmiennej Nazwa powszechnie stosowana: 3434
  Liczba etykiet zmiennej Rodzaj preparatu: 2
  Liczba etykiet zmiennej Zakaz stosowania u zwierząt: 2
  Liczba etykiet zmiennej Nazwa poprzednia produktu: 840
  Liczba etykiet zmiennej Droga podania - Gatunek - Tkanka - Okres
karencji: 1440
  Liczba etykiet zmiennej Moc: 3739
  Liczba etykiet zmiennej Postać farmaceutyczna: 468
  Liczba etykiet zmiennej Typ procedury: 5
  Liczba etykiet zmiennej Numer pozwolenia: 17042
  Liczba etykiet zmiennej Ważność pozwolenia: 1875
  Liczba etykiet zmiennej Kod ATC: 2726
  Liczba etykiet zmiennej Podmiot odpowiedzialny: 1032
  Liczba etykiet zmiennej Opakowanie: 20816
  Liczba etykiet zmiennej Substancja czynna: 9572
  Liczba etykiet zmiennej Nazwa wytwórcy: 2618
  Liczba etykiet zmiennej Kraj wytwórcy: 755
  Liczba etykiet zmiennej Nazwa importera: 450
  Liczba etykiet zmiennej Kraj importera: 219
  Liczba etykiet zmiennej Nazwa wytwórcy/importera: 3277
  Liczba etykiet zmiennej Kraj wytwórcy/importera: 997
  Liczba etykiet zmiennej Podmiot odpowiedzialny w kraju eksportu:
904
  Liczba etykiet zmiennej Kraj eksportu: 25
  Liczba etykiet zmiennej Podstawa prawna wniosku: 35
```

Dla całego zbioru danych zmienna: *Droga podania-Gatunek-Tkanka-Okres karencji* ma 1440 wartości unikatowych. Wiele z nich przekazuje tą samą informację w różnej formie np. ['dożylna', 'podanie dożylne'], ['do oczu', 'do oka']co sztucznie podnosi kardynalność. Część rekordów zawiera również kilka informacji naraz: ['dożylna /ndoustna'] lub w przypadku produktów weterynaryjny zawiera szczegółowe dane: ['Podanie dożylne - bydło - tkanki jadalne - 0 dni']. Dla uproszczenia i ograniczenia liczby kategorii do nowej zmiennej postanowiono przypisać informacje dotyczącą tylko drogi podania, a w przypadku kilku informacji wybrać tą pierwszą.

Po redukcji danych i zapisaniu wyników w nowej zmiennej *Droga podania,* kardynalność zbioru znacząco się zmniejszyła. Liczba unikalnych etykiet dla tej zmiennej wynosi 87, co stanowi 6% oryginalnej liczbie etykiet.

```
.. code:: ipython3

  un_dgto = data["Droga podania"].unique()
  lun_dgto = len(un_dgto)
  print('Liczba etykiet zmiennej cabin: {}'.format(lun_dgto))
  print(un_dgto)


.. parsed-literal::

  Liczba etykiet zmiennej cabin: 87
  ['dożylna' 'na skórę' 'doustna' 'podskórna' 'domięśniowa' 'do oka'
   'okołonerwowa' 'dokanałowa' 'w piciu' 'do ucha' 'wziewna'
   'do nosa' 'dopochwowa' 'iniekcje zwykłe' 'nasiękowa'
   'doodbytnicza' 'dotętnicza' 'okołostawowa' 'dostawowa'
   'śródskórna' 'podjęzykowa' 'na zęby' 'zewnątrzoponowa'
   'doogniskowa' 'do stosowania miejscowego' 'podpajęczynówkowa'
   'dogardłowa' 'na płytkę paznokcia' 'zewnętrzne' 'na dziąsła'
   'na śluzówkę jamy ustnej' 'do zębodołu' 'na szyjkę macicy'
   'przewodowa' 'TTS plastry' 'do dziąsła' 'do ciała jamistego'
   'do jam ciała' 'przezskórna'
   'do linii tętniczej układu dializacyjnego'
   'do pęcherza moczowego' 'dooponowa' 'dotchawicza i dooskrzelowa'
   'dootrzewnowa' 'dojelitowa' 'wewnątrzmaciczna'
   'do ciałka szklistego' 'przez nakrapianie' 'w paszy'
   'dowymieniowo' 'do umieszczania w ulu' 'doskrzydłowo' 'dosercowa'
   'drogą rozpylania' 'przez polewanie' 'kąpiel' 'Na oczy i nozdrza'
   'na zmianę chorobową' 'do jaja' 'dościęgnowo' 'na śluzówkę'
   'przez posypanie' 'nadtwardówkowa' 'pozaustrojowo' 'na strzyki'
   'implantacja' 'do gruczołu (gruczołu ślinowego)'
   'do komory przedniej oka' 'dożwaczowe' 'okołozębowe'
   'nie dotyczy' 'nasączanie iniekcyjne' 'nebulizacja' 'domacicznie'
   'wstrzyknięcie podśluzówkowe' 'do przewodu pokarmowego'
   'do worka spojówkowego'
   'do linii tętniczej krążenia pozaustrojowego'
   'do komory mózgowej' 'śródgałkowe' 'podspojówkowa'
   'podsiatkówkowa' 'dooskrzelowa' 'dokrtaniowe' 'podśluzówkowe'
   'doguzowe' 'do skorupy mózgu']
```

Drugą cechą, o wysokiej kardynalność jest *Postać farmaceutyczna* zawierająca 468 unikalnych wartości. Przykładowe etykiety to: ['Krem', 'Tabletki powlekane', 'Tabletki', 'Roztwór doustny']. W celu zredukowania z każdej etykiety wyodrębniono jedynie pierwszy wyraz. Konieczne było jednak uwzględnienie wyjątku: etykieta 'Mrożona zawiesina do podania na oczy i nozdrza', gdyż po operacji redukowała się do 'Mrożona', co zniekształcało jej znaczenie. Dlatego po redukcji dokonano korekty tej wartości na 'Zawiesina'. Po ujednoliceniu i zredukowaniu *Postaci farmaceutycznej* do *Postać farmaceutyczna RED*, liczba unikalnych etykiet zmalała do 49, co stanowi około 10% pierwotnej liczby.

```
.. code:: ipython3

  un_pf = data["Postać farmaceutyczna RED"].unique()
  lun_pf = len(un_pf)
  print('Liczba etykiet zmiennej cabin: {}'.format(lun_pf))
  print(un_pf)


.. parsed-literal::

  Liczba etykiet zmiennej cabin: 49
  ['Koncentrat' 'Krem' 'Tabletka' 'Proszek' 'Roztwór' 'Kapsułka'
   'Syrop' 'Maść' 'Żel' 'Zawiesina' 'Płyn' 'Aerozol' 'Krople'
   'Emulsja' 'Liofilizat' 'Granulat' 'Globulki' 'Czopki' 'Zioła'
   'Pastylki' 'Puder' 'Gąbka' 'Matryca' 'Pasta' 'Lakier' 'Zestaw'
   'Guma' 'Szampon' 'Plaster' 'System' 'Implant' 'Mikrowlewka' 'Gaz'
   'Generator' 'Drażetki' 'Obroża' 'Premiks' 'Dyspersja' 'Pastylka'
   'Pasek' 'Płytka' 'Piana' 'Wkład' 'Rozpuszczalnik' 'Prekursor'
   'Tkanka' 'Lamelki' 'Sztyft' 'Globulka']
```

Zmniejszenie liczby unikalnych wartości tych dwóch cech (kardynalności) zmniejsza ryzyko, że w trakcie podziału danych na zbiór treningowy i testowy w zbiorze testowym pojawią się etykiety, których model nie widział wcześniej. Przykład dla *Postaci farmaceutycznej*, *Postaci farmaceutycznej RED* i *Zakaz stosowania u zwierząt*.

```
.. code:: ipython3

  col_name = ["Postać farmaceutyczna", "Postać farmaceutyczna RED",
"Zakaz stosowania u zwierząt"]
  X = data[col_name]
  Y = data["Rodzaj preparatu"]
  X_train, X_test, Y_train, Y_test =
sl.model_selection.train_test_split(X, Y, test_size=0.2, ran-
dom_state=0)

  print(f"X_train.shape: {X_train.shape}, X_test.shape:
{X_test.shape}, Y_train.shape: {Y_train.shape}, Y_test.shape:
{Y_test.shape}")


.. parsed-literal::

  X_train.shape: (16652, 3), X_test.shape: (4164, 3), Y_train.shape:
(16652,), Y_test.shape: (4164,)
```

```
.. code:: ipython3

  for zmienna in col_name:
      Unique = [x for x in X_test[zmienna].unique() if x not in
X_train[zmienna].unique()]

      print(f"{len(Unique)} etykiet dla zmiennej '{zmienna}' nie są
obecne w zbiorze treningowym.")


.. parsed-literal::

  29 etykiet dla zmiennej 'Postać farmaceutyczna' nie są obecne w
zbiorze treningowym.
  1 etykiet dla zmiennej 'Postać farmaceutyczna RED' nie są obecne w
zbiorze treningowym.
  0 etykiet dla zmiennej 'Zakaz stosowania u zwierząt' nie są obecne
w zbiorze treningowym.
```

4.5. Wybranie kolumny, do tworzenia modelu ML jako zmienna TARGET.

Kolumna wybrana jako zmienna TARGET to *Postać farmaceutyczna RED*. Model, po nauczeniu się na przygotowanym zbiorze danych, będzie przypisywał odpowiednie etykiety oraz grupował leki zgodnie z rozpoznanymi wzorcami. Redukcja etykiet do bardziej ogólnych kategorii zmniejsza ryzyko błędów predykcji. Ma bardzo wyraźne wzorce, które wiążą się z innymi cechami, zwłaszcza *Drogą podania* oraz ma zastosowanie praktyczne.

4.6. Wybranie podzbioru zmiennych FEATURES, do wyznaczenia zmiennej TARGET.

Podzbiór zmiennych FEATURES obejmuje: *Droga podania, Moc, Nazwa powszechnie stosowana, Substancją czynna, Rodzajem preparatu, Kod ATC.* Kolumny te została wybrane, gdyż są dość mocno powiązana z *Postacią farmaceutyczną* np. [*Postać farmaceutyczna RED* - 'Tabletka', *Droga podania* - 'doustna']. *Substancją czynna* oraz *Moc* może również zawierać informacje wskazujące na formę leku, poprzez jednostki takie jak miligramy czy mililitry. Z kolei *Kod ATC* to system klasyfikacji leków, który dzieli leki na grupy anatomiczne, właściwości terapeutyczne, właściwości farmakologiczne oraz właściwości chemiczne , co może dostarczyć modelowi dodatkowego kontekstu istotnego przy przewidywaniu postaci farmaceutycznej. Dodatkowo, *Rodzaj preparatu* może mieć istotne znaczenie, ponieważ pewne postaci farmaceutyczne są charakterystyczne tylko dla jednego z tych zastosowań.

Bibliografia

https://dane.gov.pl/tools/api-validator/

https://dane.gov.pl/pl/dataset/397,rejestr-produktow-leczniczych

Kod:

https://colab.research.google.com/drive/1CUaROn8rolvfPjG6xZEZMfVpK-DV667c